

Incorporación de la filogenia de *Quercus* en los modelos de desecación

Razonamiento y proceso para la introducción de la no-independencia filogenética con
brms

Análisis del proyecto Que_bellotas

2026-08-02

Table of contents

1	Contexto y objetivo	2
2	La aproximación recomendada: modelos filogenéticos multinivel con brms	2
3	Exploración de los datos	3
3.1	Implicaciones para el flujo de trabajo	4
4	Fuente de la filogenia	5
4.1	Alternativa descartada: mega-árbol de plantas (GBOTB / V.PhyloMaker2)	6
4.2	Alternativa elegida: Open Tree of Life (OToL) vía rot1	6
4.3	El PDF no fue la fuente del árbol	6
5	Construcción del árbol (script 01-scripts/d.07.0-phylo_tree.R)	6
5.1	Resolución de nombres (TNRS)	6
5.2	Subárbol inducido	7
5.3	Problema: ausencia de longitudes de rama	7
5.4	Solución: longitudes de rama por el método de Grafen	7
5.5	Árbol resultante	8
5.6	Matriz de covarianza filogenética A	9
5.7	Advertencias sobre la filogenia	9
6	Especificación del modelo brms (script 01-scripts/d.07.1-brms_phylo_model.R)	10
6.1	Modelo M1: filogenia + procedencia + bellota	10
6.2	Modelo M2: filogenia + especie libre + procedencia + bellota	10
6.3	Priors y muestreo	10
6.4	Señal filogenética	11
7	Estado del proceso y próximos pasos	11
8	Archivos generados	11

1 Contexto y objetivo

El proyecto `Que_bellotas` analiza la velocidad de desecación de bellotas de distintas especies de roble (*Quercus*). El conjunto de datos contiene mediciones repetidas de contenido de humedad (`Moisture_content`) a lo largo del tiempo de secado (`time`) para cada bellota.

El modelo de partida (ajustado con `glmmTMB`) es:

```
m.t1 <- glmmTMB(
  Moisture_content ~ time * (Dim.1 + Dim.2 + Dim.3) + (time | id_bellota:species),
  data = df.t1
)
```

en el que se estima una pendiente y un intercepto aleatorios para cada combinación de bellota y especie. Este término recoge la no-independencia de las mediciones repetidas dentro de cada bellota.

Limitación identificada: en este modelo, cada especie se trata como si fuese independiente de las demás. Sin embargo, debido al parentesco filogenético, algunas especies están más emparentadas entre sí y cabe esperar que compartan características (p. ej., tasas de desecación o niveles iniciales de humedad). Ignorar esa estructura puede sesgar las inferencias a nivel de especie y subestimar la incertidumbre.

Objetivo: incorporar la estructura de covarianza filogenética entre las 8 especies de *Quercus* presentes en el estudio, afectando tanto a interceptos como a pendientes.

2 La aproximación recomendada: modelos filogenéticos multinivel con `brms`

La recomendación es ajustar los modelos en el marco bayesiano con el paquete `brms`, que permite especificar un término aleatorio a nivel de especie cuya estructura de covarianza viene dada por una **matriz filogenética** `A` obtenida del árbol de las especies.

La referencia metodológica es el documento “*Estimating Phylogenetic Multilevel Models with brms*” (vignette de P. Bürkner, que acompaña a `brms`). La estrategia central que se extrae de dicha vignette es:

1. Obtener el árbol filogenético (`phylo`) de las especies.
2. Construir la matriz de varianza-covarianza filogenética con `A <- ape::vcv.phylo(phylo)`.
3. Especificar el término aleatorio filogenético con `(1 | gr(species, cov = A))`, pasando la matriz `A` mediante el argumento `data2 = list(A = A)`.
4. Cuando hay varias observaciones por especie, la vignette recomienda combinar el efecto filogenético con un término de especie “libre” (`(1 | species)`) para separar la señal filogenética del efecto específico no filogenético.

5. La vignette advierte que es posible estimar **pendiente e intercepto** filogenéticos ($(1 + x | \text{gr}(\dots))$), aunque requiere productos de Kronecker de matrices de covarianza. Con 8 especies la matriz es pequeña (8×8), por lo que el coste es asumible.

i Note

La vignette **no proporciona el árbol** de las especies del estudio: usa un árbol de ejemplo (`phylo.nex`, con tips `sp_1...sp_200`) con fines ilustrativos. La metodología se tomó del PDF; la filogenia se obtuvo por otra vía (sección Section 4).

3 Exploración de los datos

Antes de plantear el modelo se verificó la estructura de los datos:

- `df.t1` tiene 2069 observaciones (tiempos < 90 h).
- 8 especies de *Quercus*: `petraea`, `robur`, `faginea`, `coccifera`, `ilex`, `pyrenaica`, `suber`, `pubescens`.
- `id_bellota` es un identificador único a nivel global (no se repite entre especies). Por tanto, el término $(\text{time} | \text{id_bellota}:\text{species})$ del modelo original equivale a $(\text{time} | \text{id_bellota})$.

i Note

¿Por qué $(\text{time} | \text{id_bellota}:\text{species})$ equivale a $(\text{time} | \text{id_bellota})$?

En `glmmTMB` (y `lme4`), el término $(\text{time} | g)$ estima un intercepto y una pendiente aleatorios para **cada nivel** del factor `g`. La expresión `id_bellota:species` es la interacción de dos factores: crea un nuevo factor cuyos niveles son todas las combinaciones únicas (`id_bellota`, `species`).

Como cada bellota pertenece a una única especie y sus valores de `id_bellota` no se repiten entre especies, la correspondencia entre $(\text{id_bellota}, \text{species})$ e `id_bellota` es **biyectiva**: ambas especificaciones tienen el mismo número de niveles y agrupan exactamente las mismas observaciones, por lo que producen la misma estructura de efectos aleatorios. La interacción solo sería necesaria si los valores de `id_bellota` se repitieran entre especies.

- `numero_bellota`: numeración de las bellotas **dentro de cada procedencia**; se reinicia en cada `codigo` (valores 1–30). La combinación `codigo × numero_bellota` identifica cada bellota de forma única (equivale a `id_bellota`).
- `codigo` (columna `prov_code` en los dataframes derivados): identificador alfanumérico único para cada combinación **especie × procedencia** (PE1, PE2, IL1, IL2, ...). Está **anidado** dentro de especie: cada `codigo` pertenece a una sola especie.
- `procedencia` (columna `provenance` en los dataframes derivados): el nombre concreto de la procedencia (p. ej. Santos de la Humosa, Región Vasco-Navarra, ...). **No está anidado** en la especie: algunos nombres de procedencia se comparten entre especies distintas (p. ej. “Alcarria-Serranía de Cuenca-Chiloeches” aparece en *Q. coccifera* y *Q. ilex*; “Alcarria-Serranía de Cuenca-Santos de la Humosa” en *Q. faginea* y *Q. ilex*). Es, por tanto, una variable **cruzada** con la especie.

La jerarquía anidada real de los datos es: **observaciones** → **bellota** (**id_bellota**) → **procedencia** (**codigo**) → **especie** (**filogenia**).

3.1 Implicaciones para el flujo de trabajo

Esta información modifica el planteamiento del modelo en varios puntos:

1. **Nivel de procedencia.** Existe un nivel de agrupación intermedio entre la bellota y la especie: la procedencia (**codigo**, 16 niveles). Es recomendable incluir un término aleatorio ($1 + \text{time} \mid \text{codigo}$) para absorber la variación entre procedencias dentro de una misma especie. De lo contrario, esa variación se confunde con el efecto de especie (filogenético o no) o infla la varianza a nivel de bellota.
2. **procedencia no es anidada.** Al compartirse nombres de procedencia entre especies, no debe especificarse **procedencia** como factor anidado en especie. Un efecto cruzado ($1 + \text{time} \mid \text{procedencia}$) sería concebible, pero con solo 2 de 15 nombres de procedencia compartidos entre especies su aportación es marginal y arriesga problemas de identificación; se recomienda modelar la procedencia mediante **codigo** (anidado).
3. **Nombre del término filogenético.** En brms no se puede usar el mismo factor dos veces con distinta estructura de covarianza. Para el modelo M2 se necesita una copia de la variable de especie (p. ej. **phylo_species** = **species**) dedicada al término con **cov = A**, mientras que **species** queda para el efecto libre no filogenético (siguiendo la recomendación de la vignette).
4. **Señal filogenética.** La fórmula de la CCI/ debe incorporar la varianza del nivel de procedencia: $\text{sd_phylo}^2 / (\text{sd_phylo}^2 + \text{sd_codigo}^2 + \text{sd_bellota}^2 + \text{sigma}^2)$.

```
df.bellotas <- read.csv("00-data/desiccation_traits_long.csv")
df.famd <- read.csv("00-data/famd_ind_coord.csv")

df.t1 <- df.bellotas |>
  dplyr::select(-X) |>
  dplyr::select(id_bellota, codigo, tiempo_acumulado_horas, Moisture_content, numero_bellota) |>
  left_join(y = df.famd, by = "id_bellota") |>
  tidyr::drop_na(Dim.1, Dim.2, Dim.3) |>
  rename(time = tiempo_acumulado_horas, id_bellota2 = numero_bellota) |>
  mutate(log.t = log(time + 1), sqrt.t = sqrt(time + 1)) |>
  filter(time < 90)

cat("Observaciones:", nrow(df.t1), "\n")
```

Observaciones: 2069

```
cat("Bellotas (id_bellota unicos):", n_distinct(df.t1$id_bellota), "\n")
```

Bellotas (id_bellota unicos): 430

```
cat("numero_bellota unicos (se reinicia por procedencia):", n_distinct(df.t1$id_bellota2), "\n")
```

numero_bellota unicos (se reinicia por procedencia): 30

```
cat("Codigos de procedencia:", n_distinct(df.t1$codigo), "\n")
```

Codigos de procedencia: 16

```
cat("Procedencias (nombre):", n_distinct(df.t1$provenance), "\n")
```

Procedencias (nombre): 14

```
cat("Especies:", n_distinct(df.t1$species), "\n")
```

Especies: 8

```
cat("Procedencias compartidas entre especies:\n")
```

Procedencias compartidas entre especies:

```
print(
  df.t1 |>
    distinct(provenance, species) |>
    group_by(provenance) |>
    summarise(n_especies = n_distinct(species), .groups = "drop") |>
    filter(n_especies > 1) |>
    as.data.frame()
)
```

	provenance	n_especies
1	Alcarria-Serranía de Cuenca-Chiloeches	2
2	Alcarria-Serranía de Cuenca-Santos de la Humosa	2

4 Fuente de la filogenia

La elección de la fuente filogenética es una decisión metodológica importante y conviene documentar las alternativas consideradas.

4.1 Alternativa descartada: mega-árbol de plantas (GBOTB / V.PhyloMaker2)

Se consideró generar el árbol con el paquete `V.PhyloMaker2`, que inserta una lista de especies en el mega-árbol de plantas vasculares GBOTB (Smith & Brown 2018; Jin & Qian 2019, 2022).

Motivo del descarte: GBOTB funciona esencialmente a nivel de género. Como las 8 especies del estudio pertenecen al mismo género (*Quercus*), la inserción las habría dejado como una **politomía de hermanas** en el nodo del género. En ese caso, todas las covarianzas de la matriz **A** habrían sido iguales y el modelo no habría tenido ninguna información filogenética que estimar (señal nula por construcción). Es decir, la herramienta es adecuada para comunidades de plantas de distintos géneros, pero no para comparar especies dentro de un género.

4.2 Alternativa elegida: Open Tree of Life (OToL) vía `rotl`

La filogenia se obtuvo del **árbol sintético de Open Tree of Life** mediante el paquete `rotl`. El árbol sintético es un consenso de filogenias moleculares publicadas, y **sí contiene filogenias intra-genéricas de *Quercus***, que es la resolución necesaria en este estudio.

Ventajas de esta elección:

- **Resolución intra-genérica:** permite diferenciar las relaciones dentro de *Quercus*, que es exactamente lo que necesita el análisis.
- **Reproducibilidad:** los identificadores de la taxonomía (OTT ids) quedan registrados y el árbol puede regenerarse en cualquier momento.
- **Transparencia:** la topología proviene de un consenso de literatura publicada, no de decisiones ad hoc.

4.3 El PDF no fue la fuente del árbol

El documento de Bürkner solo aporta la **metodología** (construcción de **A**, sintaxis `gr(cov = A)`, comparación de modelos). No contiene datos de robles; el árbol que incluye es un ejemplo genérico (`sp_1...sp_200`).

5 Construcción del árbol (script 01-scripts/d.07.0-phylo_tree.R)

5.1 Resolución de nombres (TNRS)

Se consultó la taxonomía de OToL con `tnrs_match_names()` para verificar los nombres científicos. Las 8 especies se resolvieron sin sinónimos ni errores:

```
library(rotl)
spp <- c("Quercus petraea", "Quercus robur", "Quercus faginea",
        "Quercus coccifera", "Quercus ilex", "Quercus pyrenaica",
        "Quercus suber", "Quercus pubescens")
resolved <- tnrs_match_names(spp, context_name = "Vascular plants")
```

search_string	unique_name	ott_id	is_synonym
quercus petraea	Quercus petraea	516540	FALSE
quercus robur	Quercus robur	239659	FALSE
quercus faginea	Quercus faginea	381049	FALSE
quercus coccifera	Quercus coccifera	272695	FALSE
quercus ilex	Quercus ilex	272692	FALSE
quercus pyrenaica	Quercus pyrenaica	716878	FALSE
quercus suber	Quercus suber	272709	FALSE
quercus pubescens	Quercus pubescens	426505	FALSE

5.2 Subárbol inducido

Se extrajo el subárbol inducido con `tol_induced_subtree()` a partir de los OTT ids. El subárbol resultante está **completamente resuelto** (8 tips y 7 nodos internos, es decir, árbol binario).

```
tree <- tol_induced_subtree(ott_ids = resolved$ott_id)
```

5.3 Problema: ausencia de longitudes de rama

El subárbol devuelto por OTOL **no traía longitudes de rama** (Rooted; no branch length).

¿Qué significa? Una filogenia tiene dos componentes:

- la **topología** (qué especies están emparentadas entre sí), que sí se obtuvo;
- las **longitudes de rama** (cuánta evolución o tiempo separa cada par de divergencias), que es lo que faltaba.

Las longitudes son imprescindibles porque la matriz de covarianza filogenética se construye a partir de ellas: bajo un modelo browniano de evolución, la covarianza entre dos especies es proporcional a la suma de longitudes desde la raíz hasta su ancestro común. Sin longitudes no se puede construir A.

¿Por qué faltaban? Las relaciones entre estas especies dentro del árbol sintético proceden de **inserciones taxonómicas** (sin datos moleculares datados), y esos nodos no llevan longitudes asignadas. Al inducir el subárbol, esas aristas quedaron sin longitud.

5.4 Solución: longitudes de rama por el método de Grafen

Al disponer únicamente de la topología, se asignaron longitudes con el método de **Grafen (1989)**, implementado en `ape::compute.brlen(..., method = "Grafen")`.

En qué se basa:

1. A cada nodo interno se le asigna una “altura” proporcional al número de hojas que tiene por debajo: $\text{altura}(\text{nodo}) = (\text{n_descendientes})^{\frac{1}{2}}$, con $\frac{1}{2} = 1$ por defecto.
2. La longitud de cada rama es la **diferencia de alturas** entre los dos nodos que conecta.

Propiedades:

- Produce un árbol **ultramétrico** (todas las especies equidistan de la raíz), lo que asume la mayoría de métodos comparativos.
- Las ramas cercanas a la raíz (divergencias antiguas) reciben longitudes mayores que las de clados recientes.
- Las longitudes están en **unidades arbitrarias** (número de hojas), no en tiempo ni sustituciones: es un heurístico, no un dato.

Justificación de su uso aquí: el objetivo era realizar una primera prueba metodológica. La escala absoluta de **A** no afecta a la inferencia en **brms**, porque el modelo estima un parámetro de desviación `sd_phylo` que escala la matriz (la covarianza modelada es $\text{sd}^2 \cdot \mathbf{A}$); lo relevante es la **estructura relativa** de covarianzas, que Grafen sí conserva a partir de la topología.

5.5 Árbol resultante

```
tree <- readRDS("00-data/phylo/oak_tree.rds")
plot(tree, cex = 1.2)
```




Figure 1: Filogenia de las 8 especies de *Quercus* (Open Tree of Life, longitudes de Grafen).

```
cat("Newick:\n", ape::write.tree(tree), "\n")
```

Newick:

```
((((Quercus_pyrenaica:0.2857142857,(Quercus_pubescens:0.1428571429,Quercus_faginea:0.1428571429
```


La topología resultante es:

```
((((pyrenaica, (pubescens, faginea)), (petraea, robur)), suber), (ilex, coccifera))
```

5.6 Matriz de covarianza filogenética A

```
A <- readRDS("00-data/phylo/oak_vcv.rds")
kable(round(A, 3), caption = "Matriz de varianza-covarianza filogenética (A = vcv.phylo).")
```

Table 1: Matriz de varianza-covarianza filogenética (A = vcv.phylo).

	Quercus pubescens	Quercus faginea	Quercus pyrenaica	Quercus petraea	Quer- cus robur	Quer- cus suber	Quer- cus ilex	Quercus coccifera
Quercus pubescens	1.000	0.857	0.714	0.429	0.429	0.286	0.000	0.000
Quercus faginea	0.857	1.000	0.714	0.429	0.429	0.286	0.000	0.000
Quercus pyrenaica	0.714	0.714	1.000	0.429	0.429	0.286	0.000	0.000
Quercus petraea	0.429	0.429	0.429	1.000	0.857	0.286	0.000	0.000
Quercus robur	0.429	0.429	0.429	0.857	1.000	0.286	0.000	0.000
Quercus suber	0.286	0.286	0.286	0.286	0.286	1.000	0.000	0.000
Quercus ilex	0.000	0.000	0.000	0.000	0.000	0.000	1.000	0.857
Quercus coccifera	0.000	0.000	0.000	0.000	0.000	0.000	0.857	1.000

5.7 Advertencias sobre la filogenia

1. **Posición de *Quercus suber*:** en el árbol de OTOL, *suber* aparece como hermana de los robles blancos. Sin embargo, filogenias genómicas recientes (Hipp et al. 2020) sitúan a *suber* en el subgénero *Cerris*, junto a *ilex* y *coccifera*. Esta discrepancia refleja que OTOL sintetiza distintas fuentes y la resolución a este nivel puede ser inestable.
2. **Longitudes de Grafen:** son un heurístico. Para el artículo convendría sustituirlas por una filogenia de robles *datada* (p. ej. Hipp et al.

2020) o, al menos, realizar un análisis de sensibilidad con métodos alternativos de longitudes.

3. **Número de especies:** con solo 8 especies, la señal filogenética se estima con incertidumbre alta; el término de bellota puede absorber parte de la variación entre especies. Los resultados deben interpretarse con cautela.

6 Especificación del modelo brms (script 01-scripts/d.07.1-brms_phylo_model.R)

La estructura general sigue el modelo original, sustituyendo la independencia entre especies por una covarianza filogenética, y añadiendo el término de bellota para la variación dentro de especie y el de procedencia (codigo) para la variación entre procedencias dentro de especie.

Nota previa: en brms no se puede usar el mismo factor dos veces con distinta estructura de covarianza. Por eso se crea una copia de la variable de especie dedicada al término filogenético:

```
df.t1$phylo_species <- df.t1$species
```

6.1 Modelo M1: filogenia + procedencia + bellota

```
form1 <- bf(
  Moisture_content ~ time * (Dim.1 + Dim.2 + Dim.3) +
    (1 + time | gr(phylo_species, cov = A)) + # filogenético (intercepto + pendiente)
    (1 + time | codigo) +                    # procedencia (anidada en especie)
    (1 + time | id_bellota)                  # variación entre bellotas
)
```

6.2 Modelo M2: filogenia + especie libre + procedencia + bellota

Siguiendo la recomendación de la vignette para datos con observaciones repetidas, se añade un término de especie “libre” que separa el componente filogenético del efecto específico no filogenético:

```
form2 <- bf(
  Moisture_content ~ time * (Dim.1 + Dim.2 + Dim.3) +
    (1 + time | gr(phylo_species, cov = A)) + # filogenético
    (1 + time | species) +                    # especie no filogenética
    (1 + time | codigo) +                    # procedencia (anidada en especie)
    (1 + time | id_bellota)                  # variación entre bellotas
)
```

6.3 Priors y muestreo

```
priors <- c(
  prior(normal(40, 20), class = "Intercept"),
  prior(normal(0, 10), class = "b"),
  prior(student_t(3, 0, 10), class = "sd"),
  prior(student_t(3, 0, 10), class = "sigma"),
  prior(lkj(2), class = "cor")
)
```

```
m1 <- brm(
  form1, data = df.t1, data2 = list(A = A),
  family = gaussian(), prior = priors,
  iter = 4000, warmup = 2000, chains = 4, cores = 4,
  control = list(adapt_delta = 0.95, max_treedepth = 12),
  seed = 123
)
```

6.4 Señal filogenética

Siguiendo la vignette, la señal filogenética (análoga al de Pagel, aquí como CCI) se calcula como la proporción de varianza atribuible al nivel filogenético:

```
hyp_phylo <- paste(
  "sd_phylo_species__Intercept^2 /",
  "(sd_phylo_species__Intercept^2 + sd_codigo__Intercept^2 +",
  " sd_id_bellota__Intercept^2 + sigma^2)"
)
hypothesis(m1, hyp_phylo, class = NULL)
```

7 Estado del proceso y próximos pasos

1. **Filogenia y matriz A:** completadas y guardadas en 00-data/phylo/ (oak_tree.rds, oak_tree.nwk, oak_vcv.rds).
2. **Ajuste de prueba (M1 y M2):** el primer lanzamiento se interrumpió por exceder el tiempo máximo de la sesión (la compilación del modelo Stan arrancó correctamente, confirmando que la sintaxis `gr(species, cov = A) + data2 = list(A = A)` es válida en la versión instalada de `brms`), pero el muestreo no llegó a completarse.
3. **Pendiente:**
 - completar el ajuste de M1 y M2 (más iteraciones, 4 cadenas);
 - verificar convergencia (R-hat, ESS) y diagnósticos;
 - comparar M1 vs M2 con LOO/WAIC;
 - contrastar con el modelo `glmmTMB` original;
 - **análisis de sensibilidad** de la filogenia (Grafen vs longitudes iguales vs filogenia datada de robles).

8 Archivos generados

Archivo	Contenido
01-scripts/d.07.0-phylo_tree.R	Obtención del árbol en OTOL y construcción de A
01-scripts/d.07.1-brms_phylo_model.R	Ajuste de M1 y M2 con <code>brms</code>

Archivo	Contenido
00-data/phylo/oak_tree.rds / .nwk	Árbol filogenético (topología + longitudes de Grafen)
00-data/phylo/oak_vcv.rds	Matriz de varianza-covarianza filogenética A
08-reports/d.07_brms_filogenias.qmd	Este documento

9 Referencias

- Bürkner, P.-C. *Estimating Phylogenetic Multilevel Models with brms* (vignette de **brms**, versión 2025-09-09). Documento PDF incluido en el repositorio.
- de Villemereuil, P. & Nakagawa, S. (2014). General quantitative genetic methods for comparative biology. En *Modern Phylogenetic Comparative Methods*, Springer.
- Hadfield, J. D. & Nakagawa, S. (2010). General quantitative genetic methods for comparative biology: phylogenies, taxonomies, and multi-trait models. *Journal of Evolutionary Biology*, 23, 494–508.
- Grafen, A. (1989). The phylogenetic regression. *Philosophical Transactions of the Royal Society B*, 326, 119–157.
- Smith, S. A. & Brown, J. W. (2018). Constructing a broadly inclusive seed plant phylogeny. *American Journal of Botany*, 105(3), 302–314.
- Jin, Y. & Qian, H. (2019). V.PhyloMaker: an R package that can generate very large phylogenies for vascular plants. *Ecography*, 42(8), 1353–1359.
- Jin, Y. & Qian, H. (2022). V.PhyloMaker2: an updated and enlarged R package. *Plant Diversity*, 44(4), 335–339.
- Hipp, A. L. et al. (2020). Genomic landscape of the global oak phylogeny. *New Phytologist*, 226(4), 1198–1212.