

Incorporación de la filogenia de *Quercus* en los modelos de desecación

Razonamiento y proceso para la introducción de la no-independencia filogenética con
brms

Open Code & Eliot Mompeán

2026-08-18

Table of contents

1	Contexto y objetivo	2
2	La aproximación recomendada: modelos filogenéticos multinivel con brms	3
3	Exploración de los datos	3
3.1	Implicaciones para el flujo de trabajo	4
4	Fuente de la filogenia	6
4.1	Alternativa descartada: mega-árbol de plantas (GBOTB / V.PhyloMaker2)	6
4.1.1	Verificación empírica	7
4.2	Alternativa elegida: Open Tree of Life (OToL) vía rot1	8
5	Construcción del árbol (script 01-scripts/d.05.2.phylo_data.R)	8
5.1	Resolución de nombres (TNRS)	8
5.2	Subárbol inducido	9
5.3	Problema: ausencia de longitudes de rama	9
5.4	Solución: longitudes de rama por el método de Grafen	9
5.5	Árbol resultante	10
5.6	Matriz de covarianza filogenética A	10
5.7	Advertencias sobre la filogenia	11
6	Especificación del modelo brms (script 01-scripts/d.05.3_fit_models.R)	12
6.1	Modelo M1: filogenia + procedencia + bellota	12
6.2	Modelo M2: filogenia + especie libre + procedencia + bellota	12
6.3	Modelo M3: descomposición within/between + filogenia (RECOMENDADO)	13
6.4	Priors y muestreo	14
6.4.1	Prior del intercepto: normal(40, 20)	15
6.4.2	Prior de los coeficientes: normal(0, 10)	15
6.4.3	Prior de las desviaciones estándar: student_t(3, 0, 10)	15
6.4.4	Prior de correlaciones: lkj(2)	16

6.4.5	Resumen de la estrategia de priors	17
6.5	Señal filogenética	18
7	Desarrollo del ajuste bayesiano	18
7.1	Problema 1: cuelgue en Windows con múltiples cadenas	19
7.2	Problema 2: parámetros en exceso	19
7.3	Optimización del algoritmo: plan de 48 horas	19
7.3.1	Fase 1: Prueba de configuración (4 horas)	19
7.3.2	Fase 2: Tirada completa PRE (24 horas)	20
7.3.3	Fase 3: Tirada completa POST (24 horas)	20
7.4	Tabla comparativa de configuraciones	20
8	Resultados del modelo M3	20
8.1	Fase PRE ($t < 94$ h)	20
8.1.1	Efectos fijos	20
8.1.2	Señal filogenética	21
8.1.3	Diagnósticos de convergencia	21
8.2	Fase POST ($t > 94$ h)	21
8.2.1	Efectos fijos	21
8.2.2	Diagnósticos de convergencia	22
8.3	Comparativa PRE vs POST	22
8.4	Señal filogenética	23
9	Comparación con el modelo frecuentista	23
10	Estado del proceso	23
10.1	Completado	23
10.2	Pendiente	24
11	Archivos generados	24

1 Contexto y objetivo

El proyecto `Que_bellotas` analiza la velocidad de desecación de bellotas de distintas especies de roble (*Quercus*). El conjunto de datos contiene mediciones repetidas de contenido de humedad (`Moisture_content`) a lo largo del tiempo de secado (`time`) para cada bellota.

El modelo de partida (ajustado con `glmmTMB`) es:

```
m.t1 <- glmmTMB(
  Moisture_content ~ time * (Dim.1 + Dim.2 + Dim.3) + (time | id_bellota:species),
  data = df.t1
)
```

en el que se estima una pendiente y un intercepto aleatorios para cada combinación de bellota y especie. Este término recoge la no-independencia de las mediciones repetidas dentro de cada bellota.

Limitación identificada: en este modelo, cada especie se trata como si fuese independiente de las demás. Sin embargo, debido al parentesco filogenético, algunas especies están más emparentadas entre sí y cabe esperar que compartan características (p. ej., tasas de desecación o niveles iniciales de humedad). Ignorar esa estructura puede sesgar las inferencias a nivel de especie y subestimar la incertidumbre.

Objetivo: incorporar la estructura de covarianza filogenética entre las 8 especies de *Quercus* presentes en el estudio, afectando tanto a interceptos como a pendientes.

2 La aproximación recomendada: modelos filogenéticos multinivel con brms

La recomendación es ajustar los modelos en el marco bayesiano con el paquete **brms**, que permite especificar un término aleatorio a nivel de especie cuya estructura de covarianza viene dada por una **matriz filogenética A** obtenida del árbol de las especies.

La referencia metodológica es la vignette de Bürkner (2025) que acompaña a **brms**. La estrategia central que se extrae de dicha vignette es:

1. Obtener el árbol filogenético (**phylo**) de las especies.
2. Construir la matriz de varianza-covarianza filogenética con `A <- ape::vcv.phylo(phylo)`.
3. Especificar el término aleatorio filogenético con `(1 | gr(species, cov = A))`, pasando la matriz **A** mediante el argumento `data2 = list(A = A)`.
4. Cuando hay varias observaciones por especie, la vignette recomienda combinar el efecto filogenético con un término de especie “libre” (`(1 | species)`) para separar la señal filogenética del efecto específico no filogenético.
5. La vignette advierte que es posible estimar **pendiente e intercepto** filogenéticos (`((1 + x | gr(...)))`), aunque requiere productos de Kronecker de matrices de covarianza. Con 8 especies la matriz es pequeña (8×8), por lo que el coste es asumible.

3 Exploración de los datos

Antes de plantear el modelo se verificó la estructura de los datos:

- `df.t1` tiene 2069 observaciones (tiempos < 90 h).
- 8 especies de *Quercus*: `petraea`, `robur`, `faginea`, `coccifera`, `ilex`, `pyrenaica`, `suber`, `pubescens`.
- `id_bellota` es un identificador único a nivel global (no se repite entre especies). Por tanto, el término `(time | id_bellota:species)` del modelo original equivale a `(time | id_bellota)`.

Note

¿Por qué `(time | id_bellota:species)` equivale a `(time | id_bellota)`?

En `glmmTMB` (y `lme4`), el término `(time | g)` estima un intercepto y una pendiente aleatorios para **cada nivel** del factor `g`. La expresión `id_bellota:species` es la interacción de dos factores: crea un nuevo factor cuyos niveles son todas las combinaciones únicas (`id_bellota`,

`species`).

Como cada bellota pertenece a una única especie y sus valores de `id_bellota` no se repiten entre especies, la correspondencia entre (`id_bellota`, `species`) e `id_bellota` es **biyectiva**: ambas especificaciones tienen el mismo número de niveles y agrupan exactamente las mismas observaciones, por lo que producen la misma estructura de efectos aleatorios.

- **numero_bellota**: numeración de las bellotas **dentro de cada procedencia**; se reinicia en cada `codigo` (valores 1–30). La combinación `codigo` × `numero_bellota` identifica cada bellota de forma única (equivale a `id_bellota`).
- **codigo** (columna `prov_code` en los dataframes derivados): identificador alfanumérico único para cada combinación **especie** × **procedencia** (PE1, PE2, IL1, IL2, ...). Está **anidado** dentro de especie: cada `codigo` pertenece a una sola especie.
- **procedencia** (columna `provenance` en los dataframes derivados): el nombre concreto de la procedencia (p. ej. Santos de la Humosa, Región Vasco-Navarra, ...). **No está anidado** en la especie: algunos nombres de procedencia se comparten entre especies distintas (p. ej. “Alcarria-Serranía de Cuenca-Chiloeches” aparece en *Q. coccifera* y *Q. ilex*; “Alcarria-Serranía de Cuenca-Santos de la Humosa” en *Q. faginea* y *Q. ilex*). Es, por tanto, una variable **cruzada** con la especie.

La jerarquía anidada real de los datos es: **observaciones** → **bellota** (`id_bellota`) → **procedencia** (`codigo`) → **especie** (**filogenia**).

3.1 Implicaciones para el flujo de trabajo

Esta información modifica el planteamiento del modelo en varios puntos:

1. **Nivel de procedencia.** Existe un nivel de agrupación intermedio entre la bellota y la especie: la procedencia (`codigo`, 16 niveles). Es recomendable incluir un término aleatorio (`1 + time | codigo`) para absorber la variación entre procedencias dentro de una misma especie. De lo contrario, esa variación se confunde con el efecto de especie (filogenético o no) o infla la varianza a nivel de bellota.

Nota sobre la independencia espacial: Al incluir `codigo` como efecto aleatorio con estructura independiente, asumimos que todas las procedencias son independientes entre sí. Esto es una simplificación, ya que procedencias geográficamente cercanas probablemente comparten condiciones ambientales similares (clima, suelo, altitud) que podrían correlacionarse espacialmente. Una alternativa más realista sería modelar la correlación espacial entre procedencias (p. ej. con un efecto espacial o una matriz de distancia geográfica). Sin embargo, con solo 16 procedencias y 8 especies, incluir simultáneamente correlación filogenética y espacial resultaría excesivamente complejo para los datos disponibles, incrementando drásticamente el número de parámetros y el riesgo de problemas de identificación. La simplificación a efectos aleatorios independientes es por tanto una decisión pragmática que asume que la mayor parte de la correlación espacial queda capturada por la composición de especies en cada procedencia (que ya está controlada por el término filogenético).

2. **procedencia no es anidada.** Al compartirse nombres de procedencia entre especies, no debe especificarse **procedencia** como factor anidado en especie. Un efecto cruzado (`1 + time | procedencia`) sería concebible, pero con solo 2 de 15 nombres de procedencia compartidos

entre especies su aportación es marginal y arriesga problemas de identificación; se recomienda modelar la procedencia mediante `codigo` (anidado).

3. **Nombre del término filogenético.** En `brms` no se puede usar el mismo factor dos veces con distinta estructura de covarianza. Para el modelo M2 se necesita una copia de la variable de especie (p. ej. `phylo_species = species`) dedicada al término con `cov = A`, mientras que `species` queda para el efecto libre no filogenético (siguiendo la recomendación de la vignette Bürkner (2025)).
4. **Señal filogenética.** La fórmula de la CCI/ debe incorporar la varianza del nivel de procedencia: $\text{sd_phylo}^2 / (\text{sd_phylo}^2 + \text{sd_codigo}^2 + \text{sd_bellota}^2 + \text{sigma}^2)$.

```
df.bellotas <- read.csv("00-data/desiccation_traits_long.csv")
df.famd <- read.csv("00-data/famd_ind_coord.csv")

df.t1 <- df.bellotas |>
  dplyr::select(-X) |>
  dplyr::select(id_bellota, codigo, tiempo_acumulado_horas, Moisture_content, numero_bellota) |>
  left_join(y = df.famd, by = "id_bellota") |>
  tidyr::drop_na(Dim.1, Dim.2, Dim.3) |>
  rename(time = tiempo_acumulado_horas, id_bellota2 = numero_bellota) |>
  mutate(log.t = log(time + 1), sqrt.t = sqrt(time + 1)) |>
  filter(time < 90)

cat("Observaciones:", nrow(df.t1), "\n")
```

Observaciones: 2069

```
cat("Bellotas (id_bellota unicos):", n_distinct(df.t1$id_bellota), "\n")
```

Bellotas (id_bellota unicos): 430

```
cat("numero_bellota unicos (se reinicia por procedencia):", n_distinct(df.t1$id_bellota2), "\n")
```

numero_bellota unicos (se reinicia por procedencia): 30

```
cat("Codigos de procedencia:", n_distinct(df.t1$codigo), "\n")
```

Codigos de procedencia: 16

```
cat("Procedencias (nombre):", n_distinct(df.t1$provenance), "\n")
```

Procedencias (nombre): 14

```
cat("Especies:", n_distinct(df.t1$species), "\n")
```

Especies: 8

```
cat("Procedencias compartidas entre especies:\n")
```

Procedencias compartidas entre especies:

```
print(
  df.t1 |>
    distinct(provenance, species) |>
    group_by(provenance) |>
    summarise(n_especies = n_distinct(species), .groups = "drop") |>
    filter(n_especies > 1) |>
    as.data.frame()
)
```

	provenance	n_especies
1	Alcarria-Serranía de Cuenca-Chiloeches	2
2	Alcarria-Serranía de Cuenca-Santos de la Humosa	2

4 Fuente de la filogenia

La elección de la fuente filogenética es una decisión metodológica importante y conviene documentar las alternativas consideradas.

4.1 Alternativa descartada: mega-árbol de plantas (GBOTB / V.PhyloMaker2)

Se consideró generar el árbol con el paquete *V.PhyloMaker2*, que inserta una lista de especies en el mega-árbol de plantas vasculares GBOTB (Smith and Brown 2018; Jin and Qian 2019, 2022). GBOTB es un árbol “backbone” de ~74.000 especies de plantas vasculares: bien resuelto en niveles taxonómicos altos (órdenes, familias, géneros), pero a nivel intra-genérico suele estar sin resolver.

Motivo del descarte: GBOTB funciona esencialmente a nivel de género. Como las 8 especies del estudio pertenecen al mismo género (*Quercus*), la inserción las habría dejado como una **politomía de hermanas** en el nodo del género. En ese caso, todas las covarianzas de la matriz *A* habrían sido iguales y el modelo no habría tenido ninguna información filogenética que estimar (señal nula por construcción). Es decir, la herramienta es adecuada para comunidades de plantas de distintos géneros, pero no para comparar especies dentro de un género.

4.1.1 Verificación empírica

Para documentar qué ocurre realmente, el apéndice del script 01-scripts/d.05.2.phylo_data.R ejecuta `V.PhyloMaker2::phylo.maker()` con las 8 especies en los tres escenarios de inserción que ofrece el paquete (S1, S2 y S3). Los resultados matizan y precisan el razonamiento anterior:

1. **No se produce un error.** `phylo.maker` completa y devuelve un árbol con longitudes de rama. El fallo de esta vía es **silencioso**, no un fallo de ejecución.
2. **Solo 5 de las 8 especies están en GBOTB** (`status = "prune"`): *petraea*, *faginea*, *coccifera*, *pyrenaica* y *suber*. Las 3 restantes —*robur*, *ilex* y *pubescens*— **no están en el mega-árbol** y se injertan ad hoc (`status = "bind"`).
3. **S1 y S3 producen exactamente el mismo árbol** (los newicks coinciden carácter a carácter): las especies injertadas quedan en **politomía** en el nodo de *Quercus*, todas con la misma longitud de rama, es decir, sin resolución entre ellas.
4. **S2 produce un árbol resuelto pero aleatorio**: cada especie injertada se empareja con un congénere elegido al azar, de modo que la topología cambia con la semilla de la ejecución (y difiere de la de S1/S3).
5. Las 5 especies **prune** heredan la topología interna de GBOTB, donde *suber* queda entre los robles blancos, contradiciendo la filogenia genómica de referencia (1).

```
# S1 y S3 (idénticos): robur, ilex y pubescens politómicas en el nodo de Quercus
(pubescens:11.78, ilex:11.78, robur:11.78,
  (((faginea:4.75, petraea:4.75):0.42, pyrenaica:5.17):3.51, suber:8.68):2.42, coccifera:11.0)

# S2: emparejamientos aleatorios (ejemplo de una ejecución)
(((faginea, petraea), pyrenaica), suber, coccifera),
  (pubescens, (ilex, robur)))
```




Figure 1: Topologías de *Quercus* devueltas por V.PhyloMaker2 (mega-árbol GBOTB) para las 8 especies según el escenario de inserción. En rojo, las especies no presentes en GBOTB e injertadas ad hoc (*robur*, *ilex*, *pubescens*): en S1 y S3 quedan en politomía en el nodo del género (árboles idénticos), mientras que en S2 se emparejan arbitrariamente con un congénere.

La comprobación confirma el motivo del descarte y lo precisa: la vía GBOTB no falla de forma ruidosa, sino que **no aporta resolución intra-genérica fiable**. En S1/S3 la matriz A habría tenido covarianzas idénticas entre las especies injertadas y el resto (politomía sin información filogenética); en S2 la topología habría dependido de la semilla aleatoria del emparejamiento.

4.2 Alternativa elegida: Open Tree of Life (OToL) vía rot1

La filogenia se obtuvo del **árbol sintético de Open Tree of Life** mediante el paquete `rot1`. El árbol sintético es un consenso de filogenias moleculares publicadas, y **sí contiene filogenias intra-genéricas de *Quercus***, que es la resolución necesaria en este estudio.

Ventajas de esta elección:

- **Resolución intra-genérica:** permite diferenciar las relaciones dentro de *Quercus*, que es exactamente lo que necesita el análisis.
- **Reproducibilidad:** los identificadores de la taxonomía (OTT ids) quedan registrados y el árbol puede regenerarse en cualquier momento.
- **Transparencia:** la topología proviene de un consenso de literatura publicada, no de decisiones ad hoc.

5 Construcción del árbol (script 01-scripts/d.05.2.phylo_data.R)

5.1 Resolución de nombres (TNRS)

Se consultó la taxonomía de OToL con `tnrs_match_names()` para verificar los nombres científicos. Las 8 especies se resolvieron sin sinónimos ni errores:

```
library(rot1)
spp <- c("Quercus petraea", "Quercus robur", "Quercus faginea",
        "Quercus coccifera", "Quercus ilex", "Quercus pyrenaica",
        "Quercus suber", "Quercus pubescens")
resolved <- tnrs_match_names(spp, context_name = "Vascular plants")
```

search_string	unique_name	ott_id	is_synonym
quercus petraea	Quercus petraea	516540	FALSE
quercus robur	Quercus robur	239659	FALSE
quercus faginea	Quercus faginea	381049	FALSE
quercus coccifera	Quercus coccifera	272695	FALSE
quercus ilex	Quercus ilex	272692	FALSE
quercus pyrenaica	Quercus pyrenaica	716878	FALSE
quercus suber	Quercus suber	272709	FALSE
quercus pubescens	Quercus pubescens	426505	FALSE

5.2 Subárbol inducido

Se extrajo el subárbol inducido con `tol_induced_subtree()` a partir de los OTT ids. El subárbol resultante está **completamente resuelto** (8 tips y 7 nodos internos, es decir, árbol binario).

```
tree <- tol_induced_subtree(ott_ids = resolved$ott_id)
```

5.3 Problema: ausencia de longitudes de rama

El subárbol devuelto por OTOL **no traía longitudes de rama** (Rooted; no branch length).

¿Qué significa? Una filogenia tiene dos componentes:

- la **topología** (qué especies están emparentadas entre sí), que sí se obtuvo;
- las **longitudes de rama** (cuánta evolución o tiempo separa cada par de divergencias), que es lo que faltaba.

Las longitudes son imprescindibles porque la matriz de covarianza filogenética se construye a partir de ellas: bajo un modelo browniano de evolución, la covarianza entre dos especies es proporcional a la suma de longitudes desde la raíz hasta su ancestro común. Sin longitudes no se puede construir **A**.

¿Por qué faltaban? Las relaciones entre estas especies dentro del árbol sintético proceden de **inserciones taxonómicas** (sin datos moleculares datados), y esos nodos no llevan longitudes asignadas. Al inducir el subárbol, esas aristas quedaron sin longitud.

5.4 Solución: longitudes de rama por el método de Grafen

Al disponer únicamente de la topología, se asignaron longitudes con el método de Grafen Grafen (1989), implementado en `ape::compute.brlen(..., method = "Grafen")`.

En qué se basa:

1. A cada nodo interno se le asigna una “altura” proporcional al número de hojas que tiene por debajo: $\text{altura}(\text{nodo}) = (\text{n_descendientes})^{\frac{1}{2}}$, con $\frac{1}{2} = 1$ por defecto.
2. La longitud de cada rama es la **diferencia de alturas** entre los dos nodos que conecta.

Propiedades:

- Produce un árbol **ultramétrico** (todas las especies equidistan de la raíz), lo que asume la mayoría de métodos comparativos.
- Las ramas cercanas a la raíz (divergencias antiguas) reciben longitudes mayores que las de clados recientes.
- Las longitudes están en **unidades arbitrarias** (número de hojas), no en tiempo ni sustituciones: es un heurístico, no un dato.

Justificación de su uso aquí: el objetivo era realizar una primera prueba metodológica. La escala absoluta de **A** no afecta a la inferencia en **brms**, porque el modelo estima un parámetro de desviación `sd_phylo` que escala la matriz (la covarianza modelada es $\text{sd}^2 \cdot \mathbf{A}$); lo relevante es la **estructura relativa** de covarianzas, que Grafen sí conserva a partir de la topología.

5.5 Árbol resultante

```
tree <- readRDS("00-data/phylo/oak_tree.rds")
plot(tree, cex = 1.2)
```




Figure 2: Filogenia de las 8 especies de Quercus (Open Tree of Life, longitudes de Grafen).

```
cat("Newick:\n", ape::write.tree(tree), "\n")
```

Newick:

```
(((((Quercus_pyrenaica:0.2857142857,(Quercus_pubescens:0.1428571429,Quercus_faginea:0.1428571429
```

La topología resultante es:

```
((((pyrenaica, (pubescens, faginea)), (petraea, robur)), suber), (ilex, coccifera))
```

5.6 Matriz de covarianza filogenética A

```
A <- readRDS("00-data/phylo/oak_vcv.rds")
kable(round(A, 3), caption = "Matriz de varianza-covarianza filogenética (A = vcv.phylo).")
```

Table 1: Matriz de varianza-covarianza filogenética ($A = \text{vcv.phylo}$).

	Quercus pubescens	Quercus faginea	Quercus pyrenaica	Quercus petraea	Quer- cus robur	Quer- cus suber	Quer- cus ilex	Quercus coccifera
Quercus pubescens	1.000	0.857	0.714	0.429	0.429	0.286	0.000	0.000
Quercus faginea	0.857	1.000	0.714	0.429	0.429	0.286	0.000	0.000
Quercus pyrenaica	0.714	0.714	1.000	0.429	0.429	0.286	0.000	0.000
Quercus petraea	0.429	0.429	0.429	1.000	0.857	0.286	0.000	0.000
Quercus robur	0.429	0.429	0.429	0.857	1.000	0.286	0.000	0.000
Quercus suber	0.286	0.286	0.286	0.286	0.286	1.000	0.000	0.000
Quercus ilex	0.000	0.000	0.000	0.000	0.000	0.000	1.000	0.857
Quercus coccifera	0.000	0.000	0.000	0.000	0.000	0.000	0.857	1.000

5.7 Advertencias sobre la filogenia

1. **Posición de *Quercus suber*:** en el árbol de OToL, *suber* aparece como hermana de los robles blancos. Sin embargo, filogenias genómicas recientes
 - (1) sitúan a *suber* en el subgénero *Cerris*, junto a *ilex* y *coccifera*. Esta discrepancia refleja que OToL sintetiza distintas fuentes y la resolución a este nivel puede ser inestable.
2. **Longitudes de Grafen:** son un heurístico. Para el artículo convendría sustituirlas por una filogenia de robles **datada** (p. ej. 1) o, al menos, realizar un análisis de sensibilidad con métodos alternativos de longitudes.
3. **Número de especies:** con solo 8 especies, la señal filogenética se estima con incertidumbre alta; el término de bellota puede absorber parte de la variación entre especies. Los resultados deben interpretarse con cautela.

Esta limitación es particularmente relevante porque los métodos comparativos filogenéticos dependen de comportamientos asintóticos que asumen muestras grandes. Hadfield and Nakagawa (2010) advierten explícitamente que “las inferencias estadísticas en filogenias pequeñas deben tratarse con extrema precaución”, ya que tanto los tests de ratio de verosimilitud como la información de Fisher dependen de la distribución ² asintótica, cuya aproximación es poco fiable con pocos grados de libertad filogenéticos. Con 8 especies, el número de contrastes independientes es extremadamente limitado (máximo 7 en un árbol binario), lo que implica que las estimaciones de parámetros como la señal filogenética (o CCI) y los efectos de rasgos entre especies están sujetas a una incertidumbre sustancial que puede no estar bien capturada por los intervalos de credibilidad.

Adicionalmente, trabajos recientes (Collar et al. (2016)) muestran que en filogenias pequeñas (<100 tips), los tests de modelo (como la comparación Brownian vs. Ornstein-Uhlenbeck) presentan tasas de error Tipo I inaceptablemente altas, favoreciendo falsamente modelos más complejos. Aunque nuestro enfoque bayesiano mitiga parcialmente estos problemas al evitar tests de hipótesis clásicos, la información asintótica subyacente sigue siendo relevante para la interpretación de los resultados.

6 Especificación del modelo brms (script 01-scripts/d.05.3_fit_models.R)

La estructura general sigue el modelo original, sustituyendo la independencia entre especies por una covarianza filogenética, y añadiendo el término de bellota para la variación dentro de especie y el de procedencia (`codigo`) para la variación entre procedencias dentro de especie.

Nota previa: en `brms` no se puede usar el mismo factor dos veces con distinta estructura de covarianza. Por eso se crea una copia de la variable de especie dedicada al término filogenético:

```
df.t1$phylo_species <- df.t1$species
```

6.1 Modelo M1: filogenia + procedencia + bellota

```
form1 <- bf(
  Moisture_content ~ time * (Dim.1 + Dim.2 + Dim.3) +
    (1 + time | gr(phylo_species, cov = A)) + # filogenético (intercepto + pendiente)
    (1 + time | codigo) +                    # procedencia (anidada en especie)
    (1 + time | id_bellota)                  # variación entre bellotas
)
```

6.2 Modelo M2: filogenia + especie libre + procedencia + bellota

Siguiendo la recomendación de la vignette Bürkner (2025) para datos con observaciones repetidas, se añade un término de especie “libre” que separa el componente filogenético del efecto específico no filogenético:

```
form2 <- bf(
  Moisture_content ~ time * (Dim.1 + Dim.2 + Dim.3) +
    (1 + time | gr(phylo_species, cov = A)) + # filogenético
    (1 + time | species) +                    # especie no filogenética
    (1 + time | codigo) +                    # procedencia (anidada en especie)
    (1 + time | id_bellota)                  # variación entre bellotas
)
```

6.3 Modelo M3: descomposición within/between + filogenia (RECOMENDADO)

El modelo M3 es el que responde directamente a la pregunta de investigación: ¿los rasgos influyen **dentro** o **entre** especies? Para ello, los ejes FAMD se descomponen en componentes within y between:

```
# Descomposición within/between (script d.05.1)
df.wb <- df.t1 |>
  group_by(species) |>
  mutate(
    D1_within = Dim.1 - mean(Dim.1),
    D1_between = mean(Dim.1),
    D2_within = Dim.2 - mean(Dim.2),
    D2_between = mean(Dim.2),
    D3_within = Dim.3 - mean(Dim.3),
    D3_between = mean(Dim.3)
  ) |>
  ungroup()

# Fórmula M3
form3 <- bf(
  Moisture_content ~ time_s * (D1_within + D2_within + D3_within +
                                D1_between + D2_between + D3_between) +
  (1 + time_s | gr(phylo_species, cov = A)) + # filogenético
  (1 + time_s | codigo) +                     # procedencia
  (1 | id_bellota)                            # bellota (solo intercepto)
)
```

Justificación de la descomposición within/between:

La técnica empleada se conoce como *within-group centering* (Pol and Wright (2009)) y consiste en separar cada predictor en su componente within (desviación de la media de la especie) y between (media de la especie). En el contexto filogenético, esta descomposición es fundamental porque permite distinguir formalmente entre dos procesos biológicos distintos (Villemereuil and Nakagawa (2014)):

- **Efectos between** (media de especie): reflejan procesos adaptativos a largo plazo. Si una especie tiene un valor medio de rasgo mayor que otra y sistemáticamente deseca más lento, esto sugiere que la selección natural ha favorecido ese rasgo a nivel de linaje.
- **Efectos within** (desviación de la media): reflejan plasticidad fenotípica, variación ambiental o respuestas facultativas. Si una bellota concreta se desvía de la media de su especie y esto afecta su tasa de desecación, se trata de un efecto de nivel individual, no evolutivo.

Sin esta separación, un modelo que use los rasgos originales (como M1/M2) produce estimadores que **confunden** ambos procesos. Como muestran Pol and Wright (2009), cuando los efectos within y between difieren en magnitud o dirección, el modelo estándar produce estimadores sesgados que no representan fielmente ninguno de los dos procesos. En nuestro caso, la descomposición permite responder directamente a la pregunta: ¿los rasgos de bellota influyen en la desecación a través de la

selección entre especies (proceso evolutivo) o a través de la variación individual dentro de especies (proceso ecológico)? Un análisis más detallado de esta justificación se encuentra en el documento 08-reports/Heterogeneous_effects_acorn_traits.qmd.

Diferencias clave con M1/M2:

- Los predictores son **within** (efecto de desviarse de la media de la especie) y **between** (media de la especie), no los rasgos originales.
- (1 | id_bellota) en vez de (1 + time_s | id_bellota): la pendiente within-bellota se absorbe en el error (justificación abajo).
- No incluye (1 + time_s | species) como M2 (con solo 8 especies, demasiado ambicioso).

Justificación de la simplificación (1 | id_bellota):

El modelo completo con (1 + time_s | id_bellota) generaba ~2900 parámetros, produciendo ~60 violaciones de `max_treedepth=12`. El análisis de componentes mostró que la pendiente within-bellota es pequeña (`var=0.0015`) comparada con el intercepto (`var=150`). Eliminar la pendiente reduce los parámetros a ~2420 y el `treedepth` al 17%, sin afectar a los efectos fijos (correlación `r=0.999`).

6.4 Priors y muestreo

```
priors <- c(  
  prior(normal(40, 20), class = "Intercept"),  
  prior(normal(0, 10), class = "b"),  
  prior(student_t(3, 0, 10), class = "sd"),  
  prior(student_t(3, 0, 10), class = "sigma"),  
  prior(lkj(2), class = "cor")  
)  
  
# Configuración final (tras pruebas de optimización)  
m3 <- brm(  
  form3, data = df.wb, data2 = list(A = A),  
  family = gaussian(), prior = priors,  
  iter = 4000, warmup = 2000, chains = 4, cores = 4,  
  control = list(adapt_delta = 0.99, max_treedepth = 14),  
  seed = 123  
)
```

Justificación detallada de los priors:

En inferencia bayesiana, un *prior* es la distribución de probabilidad que asumimos **antes** de ver los datos para cada parámetro del modelo. Los priors se clasifican en:

- **Informativos:** reflejan conocimiento previo específico sobre el parámetro. Ejemplo: `normal(50, 5)` para un intercepto si sabemos que el contenido de humedad ronda el 50% con poca variación.

- **Débilmente informativos (*weakly informative*):** imponen restricciones razonables pero no dominan la inferencia. Ejemplo: `normal(0, 10)` para un coeficiente permite valores entre -20 y 20 con baja probabilidad, pero no fuerza el resultado hacia ningún valor concreto.
- **No informativos (planos):** `flat` sobre los reales; no restringen el parámetro en absoluto. Pueden causar problemas de convergencia porque permiten valores extremadamente improbables.

Bürkner (Bürkner (2025)) destaca que el uso de priors informativos o débilmente informativos no es estrictamente necesario para la convergencia, pero **ayuda significativamente a la velocidad de muestreo** en modelos filogenéticos complejos. Los priors actúan como *regularización*: evitan que el muestreador explore regiones del espacio paramétrico donde la verosimilitud es prácticamente cero, acelerando la convergencia. En nuestro caso, dado que el ajuste del modelo M3 fue costoso (20–24 h), la elección de priors débilmente informativos fue una decisión estratégica para reducir el tiempo de muestreo sin comprometer la objetividad de los resultados.

6.4.1 Prior del intercepto: `normal(40, 20)`

El contenido de humedad (`Moisture_content`) se mide en porcentaje y ronda valores entre 0% y 100%. Un intercepto de 40% con desviación estándar de 20 permite valores entre 0 y 80 con probabilidad razonable. Este prior es **débilmente informativo**: refleja el conocimiento de que la humedad inicial de las bellotas está en ese rango, pero no fuerza el resultado. Sin este prior, el muestreador podría explorar valores negativos de humedad o valores superiores al 100%, lo cual es biológicamente imposible y ralentiza la convergencia.

6.4.2 Prior de los coeficientes: `normal(0, 10)`

Los coeficientes de los efectos fijos (incluyendo las interacciones con `time_s`) representan cambios en el contenido de humedad por unidad de cambio en el predictor. Un prior `normal(0, 10)` permite que los coeficientes varíen ampliamente (hasta ± 20 con probabilidad razonable) pero penaliza valores extremos. Esto es coherente con la escala de la variable respuesta: un coeficiente de 10 implicaría un cambio de 10 puntos porcentuales de humedad por unidad de predictor, lo cual sería un efecto extremadamente grande.

6.4.3 Prior de las desviaciones estándar: `student_t(3, 0, 10)`

Las desviaciones estándar de los efectos aleatorios (`sd_phylo`, `sd_codigo`, `sd_bellota`) y el residuo (`sigma`) están restringidas a ser positivas. El prior `student_t(3, 0, 10)` (cola pesada con 3 grados de libertad) es la elección recomendada por Bürkner (2025) porque:

1. **Colas pesadas:** la distribución Student-t con 3 gl permite valores grandes sin asignarles probabilidad despreciable, lo cual es útil cuando no se conoce bien la escala de las desviaciones.
2. **Centrado en 0:** refleja la suposición de que las desviaciones estándar son pequeñas pero no nulas.
3. **Mejor convergencia que Cauchy:** como señala Bürkner (2025), este prior “a menudo conduce a una mejor convergencia que un prior half-Cauchy, mientras sigue siendo relativamente débilmente informativo”.

El parámetro de escala 10 es el mínimo que brms usa por defecto; se ajusta automáticamente si la desviación estándar de la respuesta es mayor.

6.4.4 Prior de correlaciones: lkj(2)

El prior LKJ (Lewandowski et al. (2009)) se usa para las correlaciones entre efectos aleatorios dentro del mismo nivel (p. ej. la correlación entre intercepto y pendiente filogenéticos). Con $\nu = 2$:

- La **matriz de identidad** (correlaciones = 0) es el **modo** de la distribución, es decir, el valor más probable a priori.
- Las correlaciones extremas (± 1) son penalizadas, pero no imposibles.
- Es equivalente a una distribución beta(2, 2) aplicada a cada correlación.

Si se usara lkj(1) (el valor por defecto de brms), todas las matrices de correlación serían igualmente probables a priori, lo cual podría permitir correlaciones espurias en modelos complejos. Con lkj(2) favorecemos moderadamente la independencia entre efectos, lo que ayuda a la convergencia sin introducir sesgo sustancial.

i Aclaraciones conceptuales sobre priors

¿Qué es una distribución Cauchy / half-Cauchy?

La distribución Cauchy es una distribución de cola pesada (más pesada que la normal) que no tiene media ni varianza definidas (son infinitas). La *half-Cauchy* es simplemente la distribución Cauchy truncada en cero (solo valores positivos), usada para parámetros que deben ser positivos como desviaciones estándar. Gelman et al. (2006) recomendaban **half-Cauchy**(0, 2.5) como prior para desviaciones estándar. Sin embargo, Bürkner observó que **Student-t**(3, 0, 10) conduce a mejor convergencia porque: (1) Cauchy tiene colas tan pesadas que el muestreador puede explorar valores extremadamente grandes (ej. $\theta = 1000$), desperdiciando iteraciones; (2) Student-t(3) tiene colas pesadas pero no tanto, permitiendo valores grandes sin ser excesivamente permisiva.

La matriz de identidad y las correlaciones = 0

La matriz de identidad es una matriz cuadrada con 1s en la diagonal y 0s fuera de ella:

	[,1]	[,2]	[,3]	
[1,]	1	0	0	Diagonal = 1: correlación de un parámetro consigo misma (siempre = 1)
[2,]	0	1	0	
[3,]	0	0	1	Fuera de diagonal = 0: no hay correlación entre parámetros distintos

Cuando decimos que LKJ(2) “favorece la matriz de identidad”, significa que lo más probable a priori es que los efectos aleatorios sean **independientes** entre sí. Por ejemplo, que el intercepto filogenético y la pendiente filogenética no estén correlacionados.

¿Cómo penaliza LKJ(2) las correlaciones extremas?

Para un caso simple con 2 efectos (intercepto + pendiente), la matriz de correlación es 2x2 con un solo parámetro libre (la correlación entre ambos):

	[,1]	[,2]	
[1,]	1		= correlación entre intercepto y pendiente (varía de -1 a +1)

[2,]

1

Bajo LKJ(), la distribución de ρ depende de η :

	$\eta = 0$ (independencia)	$\eta = \pm 0.9$ (extrema)
1	Uniforme (igual prob.)	Misma prob. que $\eta = 0$
2	Modo (más probable)	Probabilidad reducida
3	Aún más probable	Aún menos probable

Con $\eta = 2$, la distribución de ρ tiene forma de campana centrada en 0: $\rho = 0$ es el valor más probable, $\rho = \pm 0.9$ es posible pero menos probable, y $\rho = \pm 1$ (correlación perfecta) tiene probabilidad cero.

¿Qué es una distribución beta(2, 2)?

La distribución beta(,) define probabilidades sobre el intervalo [0, 1]. Sus parámetros α y β controlan la forma:

beta(1, 1) → Uniforme (todos los valores igual de probables)

beta(2, 2) → Campana centrada en 0.5 (valores extremos menos probables)

beta(0.5, 0.5) → U-shaped (valores extremos MÁS probables)

Para LKJ(2), la correlación ρ se transforma a [0, 1] como $(\rho + 1)/2$, y la distribución resultante es beta(2, 2): centrada en 0 (que corresponde a $\rho = 0$, independencia), con colas que decaen hacia ± 1 (correlaciones extremas son improbables) y simétrica (no favorece correlaciones positivas sobre negativas).

6.4.5 Resumen de la estrategia de priors

Parámetro	Prior	Tipo	Justificación
Intercepto	normal(40, 20)	Débilmente informativo	Rango razonable de humedad (0–80%)
Coeficientes	normal(0, 10)	Débilmente informativo	Penaliza efectos extremos (>10 puntos)
Desviaciones	student_t(3, 0, 10)	Débilmente informativo	Colas pesadas, mejor convergencia que Cauchy
Residuo	student_t(3, 0, 10)	Débilmente informativo	Mismas razones que las desviaciones
Correlaciones	lkj(2)	Débilmente informativo	Favorece independencia, penaliza correlaciones extremas

En conjunto, estos priors representan una estrategia **conservadora**: no imponen resultados concretos, pero restringen el espacio paramétrico a valores biológicamente plausibles, acelerando el muestreo en un modelo con ~2400 parámetros que de otro modo requeriría considerablemente más tiempo.

6.5 Señal filogenética

Siguiendo la vignette Bürkner (2025), la señal filogenética (análoga al `sd_phylo` de Pagel, aquí como CCI) se calcula como la proporción de varianza atribuible al nivel filogenético:

```
hyp_phylo <- paste(
  "sd_phylo_species__Intercept^2 /",
  "(sd_phylo_species__Intercept^2 + sd_codigo__Intercept^2 +",
  " sd_id_bellota__Intercept^2 + sigma^2)"
)
hypothesis(m3, hyp_phylo, class = NULL)
```

Equivalencia entre `sd_phylo` de Pagel y CCI/ICC:

El parámetro estimado por esta fórmula es matemáticamente equivalente al `sd_phylo` de Pagel (Grafen (1989)) bajo un modelo de movimiento browniano. Para entender esta equivalencia, conviene definir los conceptos implicados:

- **Movimiento browniano (BM):** es un modelo estocástico de evolución de rasgos en el que los cambios en el valor del rasgo a lo largo de las ramas del árbol filogenético se modelan como un proceso de Wiener. Bajo BM, dos especies más emparentadas (con ancestro común más reciente) tienden a tener valores de rasgo más similares que especies distantes. La varianza acumulada es proporcional al tiempo evolutivo transcurrido.
- **`sd_phylo` de Pagel:** es un parámetro de escala que comprime o estira las longitudes de rama del árbol para evaluar cuánta de la covarianza filogenética observada es real. Varía de 0 (sin señal filogenética, todas las especies independientes) a 1 (señal completa, movimiento browniano perfecto). Cuando `sd_phylo = 0.5`, por ejemplo, la covarianza filogenética se reduce a la mitad.
- **Correlación intraclase (ICC):** en el contexto de modelos multinivel, la ICC mide la proporción de varianza total explicada por un nivel de agrupación. En nuestro caso, la ICC filogenética es $\text{sd_phylo}^2 / (\text{sd_phylo}^2 + \text{sd_otros}^2)$, que estima qué fracción de la varianza del contenido de humedad se debe a la similitud filogenética entre especies.

Bajo el modelo de movimiento browniano, `sd_phylo` y la ICC filogenética son **matemáticamente equivalentes**: ambos quantifican la misma cosa (la proporción de varianza debida a la filogenia), solo que desde marcos conceptuales distintos (evolución comparativa vs. diseño multinivel). Esta equivalencia está documentada tanto en la vignette de Bürkner (2025) como en Villemereuil and Nakagawa (2014), quienes muestran que el modelo filogenético mixto de brms produce estimaciones consistentes con el `sd_phylo` cuando se especifica correctamente la estructura de covarianza.

7 Desarrollo del ajuste bayesiano

El ajuste del modelo M3 no fue inmediato. Se necesitaron múltiples iteraciones para resolver problemas técnicos y optimizar la configuración del algoritmo.

7.1 Problema 1: cuelgue en Windows con múltiples cadenas

El primer intento de ajuste con `cores = 4` quedó colgado indefinidamente. En Windows, `brms` usa `parallel::mclapply()` que no funciona correctamente con más de 1 núcleo. La solución fue:

```
# Opción A: 1 sola cadena (lento pero funcional)
m3 <- brm(..., chains = 1, cores = 1)

# Opción B: 4 cadenas secuenciales (recomendado)
options(mc.cores = 1)
m3 <- brm(..., chains = 4, cores = 1)
```

Decisión: se usó la opción B (4 cadenas secuenciales) para mantener la diagnóstica de convergencia entre cadenas.

7.2 Problema 2: parámetros en exceso

El modelo completo con $(1 + \text{time_s} \mid \text{id_bellota})$ generaba ~2900 parámetros, produciendo ~60 violaciones de `max_treedepth=12` (21% de iteraciones). El análisis de componentes reveló:

Componente	Varianza	Proporción
Intercepto bellota	150.2	99.9%
Pendiente bellota	0.0015	0.1%

La pendiente within-bellota era despreciable. Simplificar a $(1 \mid \text{id_bellota})$ eliminó ~480 parámetros sin afectar los efectos fijos (correlación $r=0.999$).

7.3 Optimización del algoritmo: plan de 48 horas

Se diseñó un plan de pruebas sistemático para encontrar la configuración óptima:

7.3.1 Fase 1: Prueba de configuración (4 horas)

```
# Configuración mínima para verificar que el modelo compila y samplea
m_test <- brm(
  form3, data = df.wb, data2 = list(A = A),
  family = gaussian(), prior = priors,
  iter = 200, warmup = 100, chains = 2,
  control = list(adapt_delta = 0.95, max_treedepth = 12),
  seed = 123
)
```

Resultado: compiló y sampleó correctamente. Se confirmó la viabilidad.

7.3.2 Fase 2: Tirada completa PRE (24 horas)

```
m3_pre <- brm(  
  form3, data = df.wb.pre, data2 = list(A = A),  
  family = gaussian(), prior = priors,  
  iter = 4000, warmup = 2000, chains = 4,  
  control = list(adapt_delta = 0.99, max_treedepth = 14),  
  seed = 123  
)
```

7.3.3 Fase 3: Tirada completa POST (24 horas)

```
m3_post <- brm(  
  form3, data = df.wb.post, data2 = list(A = A),  
  family = gaussian(), prior = priors,  
  iter = 4000, warmup = 2000, chains = 4,  
  control = list(adapt_delta = 0.99, max_treedepth = 14),  
  seed = 123  
)
```

7.4 Tabla comparativa de configuraciones

Configuración	Parámetros	Treedepth	Divergencias	Tiempo
Completo ((1+time\ bellota))	~2900	60% violaciones	0	~24h
Simplificado ((1\ bellota))	~2420	17% violaciones	0	~18h
Final (adapt=0.99, td=14)	~2420	0.07%	0.12%	~20h

La configuración final (adapt_delta=0.99, max_treedepth=14) eliminó casi todas las violaciones de treedepth y mantuvo las divergencias por debajo del 0.2%.

8 Resultados del modelo M3

8.1 Fase PRE ($t < 94$ h)

8.1.1 Efectos fijos

Parámetro	Estimada	IC 90%	Significativo
Intercepto	49.4	(48.1 – 50.7)	
time_s	-2.45	(-2.87 – -2.04)	
D1_within	1.11	(0.80 – 1.43)	
D2_within	-1.06	(-1.47 – -0.66)	
D3_within	-0.65	(-1.07 – -0.24)	
D1_between	0.67	(-2.00 – 3.26)	
D2_between	0.20	(-3.37 – 3.67)	
D3_between	-1.04	(-5.13 – 2.93)	
time_s:D1_within	1.77	(1.54 – 2.00)	
time_s:D2_within	-0.91	(-1.22 – -0.59)	
time_s:D3_within	-0.54	(-0.86 – -0.23)	
time_s:D1_between	0.24	(-0.54 – 1.03)	
time_s:D2_between	0.04	(-0.78 – 0.87)	
time_s:D3_between	-0.25	(-1.17 – 0.68)	

Interpretación: Los efectos **within** son significativos e interactúan con el tiempo. Los efectos **between** no son significativos (CIs incluyen 0).

8.1.2 Señal filogenética

Estimada	IC 90%
0.16	0 – 0.58

Señal filogenética **baja** (16%), con alta incertidumbre.

8.1.3 Diagnósticos de convergencia

Métrica	Resultado	Criterio
Treedepth	6/8000 (0.07%)	< 30%
Divergencias	10/8000 (0.12%)	< 20
Rhat máximo	1.01	< 1.05
ESS mínimo	697 (time_s:D3_within)	> 400

Convergencia excelente.

8.2 Fase POST (t > 94 h)

8.2.1 Efectos fijos

Parámetro	Estimada	IC 90%	Significativo
Intercepto	49.4	(48.1 – 50.7)	
time_s	-2.45	(-2.87 – -2.04)	
D1_within	0.61	(0.29 – 0.92)	
D2_within	-0.61	(-1.07 – -0.15)	
D3_within	-0.15	(-0.62 – 0.33)	
D1_between	1.02	(-1.65 – 3.73)	
D2_between	0.57	(-2.91 – 4.33)	
D3_between	-2.00	(-6.34 – 2.01)	
time_s:D1_within	0.39	(0.32 – 0.46)	
time_s:D2_within	-0.01	(-0.10 – 0.08)	
time_s:D3_within	0.01	(-0.08 – 0.10)	
time_s:D1_between	-0.04	(-0.31 – 0.23)	
time_s:D2_between	-0.04	(-0.31 – 0.23)	
time_s:D3_between	0.04	(-0.24 – 0.32)	

Interpretación: Los efectos within se **atenuaron** respecto a PRE. Solo D1_within mantiene interacción significativa con el tiempo.

8.2.2 Diagnósticos de convergencia

Métrica	Resultado	Criterio
Treedepth	1/8000 (0.01%)	< 30%
Divergencias	10/8000 (0.12%)	< 20
Rhat máximo	1.02	< 1.05
ESS mínimo	219 (D3_within)	< 400

Convergencia buena, con algunos parámetros con ESS bajo (D3_within=219).

8.3 Comparativa PRE vs POST

Parámetro	PRE (t < 94h)	POST (t > 94h)	Cambio
D1_within	1.11	0.61	-45%
D2_within	-1.06	-0.61	-42%
D3_within	-0.65	-0.15	Eliminado
time_s:D1_within	1.77	0.39	-78%
time_s:D2_within	-0.91	-0.01	Eliminado
time_s:D3_within	-0.54	0.01	Eliminado
Señal filogenética	0.16	0.28	+75%
Sigma	0.68	1.15	+69%

Hallazgo principal: Los efectos de los rasgos son **dependientes de la fase**: significativos en la fase inicial (PRE), atenuados o eliminados en la fase posterior (POST). Esto sugiere que los rasgos influyen principalmente en el secado superficial rápido, no en la pérdida de agua interna posterior.

8.4 Señal filogenética

Fase	Estimada	IC 90%
PRE	0.16	0 – 0.58
POST	0.28	0 – 0.72

Señal filogenética **baja** en ambas fases, con IC amplios que se solapan.

9 Comparación con el modelo frecuentista

El modelo glmmTMB frecuentista (`d.05.1`) mostraba efectos **between** significativos, mientras que el M3 bayesiano no. La diferencia se explica por la estructura del modelo:

Característica	glmmTMB (frecuentista)	M3 (bayesiano)
Efectos between	Significativos	No significativos
Efectos filogenéticos	No incluidos	Incluidos
Efecto código	Incluido	Incluido
Efecto species	No incluido	Incluido (filogenético)

Explicación: En glmmTMB, al no incluir la filogenia ni **species** como aleatorio, la varianza que M3 atribuye a estos niveles se confunde con los efectos between. El M3 **absorbe** esa varianza en los términos aleatorios, dejando los efectos between sin señal.

Implicación: Los efectos between que parecían significativos en glmmTMB eran probablemente **confundidos** con diferencias filogenéticas o de especie. El modelo M3, al controlar por estos factores, muestra que los rasgos no tienen efecto between significativo.

10 Estado del proceso

10.1 Completado

- ☑ Filogenia y matriz A obtenidas (OToL + Grafen)
- ☑ Modelo M3 ajustado y guardado (`00-data/phylo/m3_final.rds`)
- ☑ Convergencia verificada (Rhat, ESS, treedepth, divergencias)
- ☑ Comparación PRE vs POST realizada
- ☑ Comparación con glmmTMB frecuentista documentada

10.2 Pendiente

- ☐ Ajustar M1 y M2 (si se desea completar la comparación de modelos)
- ☐ Análisis de sensibilidad de la filogenia (Grafen vs longitudes iguales vs filogenia datada de robles)
- ☐ Figuras de publicación (efectos marginales, forest plots)
- ☐ Tabla comparativa para el paper

11 Archivos generados

Archivo	Contenido
01-scripts/d.05.2.phylo_data.R	Obtención del árbol en OTOL y construcción de A
01-scripts/d.05.3_fit_models.R	Ajuste del modelo M3 con brms
00-data/phylo/oak_tree.rds / .nwk	Árbol filogenético (topología + longitudes de Grafen)
00-data/phylo/oak_vcv.rds	Matriz de varianza-covarianza filogenética A
00-data/phylo/m3_final.rds	Modelos M3 PRE y POST ajustados
00-data/phylo/m3_phylo_wb_pre.rds	Modelo M3 PRE (brmsfit)
00-data/phylo/m3_phylo_wb_post.rds	Modelo M3 POST (brmsfit)
07-img/trace_m3_pre.png	Traceplots de cadenas M3 PRE
07-img/trace_m3_post.png	Traceplots de cadenas M3 POST
08-reports/d.07_brms_filogenias.qmd	Este documento

Bürkner, Paul-Christian. 2025. *Estimating Phylogenetic Multilevel Models with brms*. <https://doi.org/10.32614/CRAN.package.brms>.

Collar, Daniel C., Evan J. Rehm, Amanda H. Freedman, et al. 2016. “A Cautionary Note on the Use of Ornstein–Uhlenbeck Models in Macroevolutionary Studies.” *Biological Journal of the Linnean Society* 118 (1): 64–77. <https://doi.org/10.1111/bij.12725>.

Grafen, Alan. 1989. “The Phylogenetic Regression.” *Philosophical Transactions of the Royal Society of London. Series B, Biological Sciences* 326 (1233): 119–57. <https://doi.org/10.1098/rstb.1989.0106>.

Hadfield, Jarrod D., and Shinichi Nakagawa. 2010. “General Quantitative Genetic Methods for Comparative Biology: Phylogenies, Taxonomies and Multi-Trait Models for Continuous and Categorical Characters.” *Journal of Evolutionary Biology* 23 (3): 494–508. <https://doi.org/10.1111/j.1420-9101.2009.01915.x>.

Jin, Yi, and Hong Qian. 2019. “V.PhyloMaker: An R Package That Can Generate Very Large Phylogenies for Vascular Plants.” *Ecography* 42 (8): 1353–59. <https://doi.org/10.1111/ecog.04434>.

Jin, Yi, and Hong Qian. 2022. “V.PhyloMaker2: An Updated and Enlarged R Package That Can Generate Very Large Phylogenies for Vascular Plants.” *Plant Diversity* 44 (4): 335–39. <https://doi.org/10.1016/j.pld.2022.05.005>.

- Lewandowski, Daniel, Dorota Kurowicka, and Harry Joe. 2009. “Generating Random Correlation Matrices Based on Vines and Extended Onion Method.” *Journal of Multivariate Analysis* 100 (9): 1989–2001. <https://doi.org/10.1016/j.jmva.2009.04.008>.
- Pol, Martijn van de, and Jonathan Wright. 2009. “A Simple Method for Distinguishing Within-Versus Between-Subject Effects Using Mixed Models.” *Animal Behaviour* 77 (3): 753–58. <https://doi.org/10.1016/j.anbehav.2008.11.006>.
- Smith, Stephen A., and Joseph W. Brown. 2018. “Constructing a Broadly Inclusive Seed Plant Phylogeny.” *American Journal of Botany* 105 (3): 302–14. <https://doi.org/10.1002/ajb2.1019>.
- Villemereuil, Pierre de, and Shinichi Nakagawa. 2014. “General Quantitative Genetic Methods for Comparative Biology.” In *Modern Phylogenetic Comparative Methods and Their Application in Evolutionary Biology: Concepts and Practice*, edited by László Zsolt Garamszegi. Springer. https://doi.org/10.1007/978-3-662-43550-2_11.